

확산 모델 기반 스켈레톤 포즈 편집 기법*

권보미, 이기용
숙명여자대학교 컴퓨터과학과, 소프트웨어학부
{bomi9970, kiyonglee}@sookmyung.ac.kr

Diffusion-based Skeleton Pose Editing

Bomi Kwon, Ki Yong Lee
Department of Computer Science, Division of Software
Sookmyung Women's University

요약

본 논문에서는 지시어 기반 부위별 스켈레톤 포즈 편집을 위한 마스크 조건부 확산 모델을 제안한다. 제안 방법은 자연어 지시어를 10개 편집 명령 카테고리로 매핑하고, 해당 부위에 대한 마스크를 자동 생성하여 편집 영역만 선택적으로 수정한다. 또한 비편집 영역은 추론 과정에서 원본으로 유지하고, 22차원 방향 벡터 표현을 사용하여 편집 중 비현실적 골격 변형을 줄이도록 하였다. 실험 결과, 제안 방법은 평균 96.7%의 지시어 일치율과 실제 데이터 대비 약 66% 수준의 편집 다양성을 보여, 정적 2D 스켈레톤 포즈 편집에서 지시어 반영과 구조 보존을 동시에 달성함을 확인하였다.

1. 서론

2D 스켈레톤 포즈에서 특정 부위만 편집하는 기술은 산업 안전 시나리오 구축과 자세 인식 모델의 데이터 증강 등에서 활용될 수 있다. 그러나 기존 인체 동작 연구는 대부분 포즈를 처음부터 생성하는 데 초점을 두어 원본 보존과 국소 편집을 직접 다루기 어렵다. 최근 확산 모델(diffusion model) 기반 인체 동작 편집 연구[1-3]는 주로 시간 축을 포함한 3차원 모션 시퀀스를 중심으로 발전해 왔으며, 정적 2D 스켈레톤 포즈의 부위별 편집을 위한 프레임워크는 제한적이다. 특히 “원팔을 올려”와 같은 자연어 지시로 해당 부위만 수정하고 나머지 자세는 그대로 유지하는 문제는 편집 부위 식별, 비편집 영역 보존, 지시 방향과 일치하는 결과 생성이라는 별도의 요구를 가진다.

본 논문에서는 이러한 요구를 동시에 만족하는 마스크 조건부 확산 기반 포즈 편집 기법을 제안한다. 제안 방법은 원본 포즈와 자연어 지시어를 입력받아 지시어를 10개의 부위/방향 편집 명령 중 하나로 해석하고, 대응되는 편집 영역 마스크를 자동 생성한다. 이후 확산 모델은 마스크된 각도 차원만을 대상으로 노이즈 제거를 수행하며, 각 추론 단계에서 비편집 영역을 원본으로 덮어쓰는 인페인팅 방식을 적용해 원본 자세를 보존한다. 또한 각 뼈대의 방향을 방위각과 고도각으로 나타낸 22차원 벡터를 사용하여, 편집 과정에서 비현실적 골격 변형을 줄이도록 하였다. 총 1,500회 편집 평가에서 제안 방법은 96.7%의 명령 일치율과 0.38의 낮은 보존 오차를 기록하였으며, 편집 영역의 샘플 다양성도 실제 데이터 대비 66% 수준을 유지

하였다. 이는 정적 2D 포즈 편집에서 방향 제어, 구조 보존, 자연스러운 다양성을 동시에 달성하였음을 보여준다.

2. 관련 연구

텍스트 기반 인체 동작 편집은 MDM[1], MotionDiffuse[2]의 모션 생성 연구를 바탕으로 발전하여, MotionFix[3]와 같은 편집 전용 데이터 및 모델로 확장되고 있다. 또한 MDM[1]은 마스크된 관절을 복원하는 인페인팅 기반 편집 가능성을 제시하였다. 그러나 이러한 연구들은 대부분 시간 축을 포함한 3차원 모션 시퀀스를 대상으로 한다. 본 연구는 정적 2D 포즈의 부위별 편집에 초점을 두고, 자연어 지시어에 따라 편집 부위만 수정하면서 비편집 영역은 원본 그대로 보존하는 마스크 조건부 편집 구조를 제안한다는 점에서 차별된다.

3. 제안 방법


3.1 전체 구조 및 포즈 표현

그림 1은 제안 방법의 전체 파이프라인을 보여준다. 입력은 원본 스켈레톤 포즈 x_{src} 와 자연어 지시어 T 이다. T 는 사전 학습된 텍스트 인코더의 임베딩과 10개 편집 명령 프로토타입 간 코사인 유사도를 통해 편집 명령 ID c 로 매핑된다. 각 명령 ID에 따라 편집 부위 마스크 $m \in \{0, 1\}^{22}$ 가 자동 생성되며, 확산 모델은 마스크된 원본 포즈, 편집 명령 임베딩, 그리고 마스크를 조건으로 편집된 포즈 x_{edit} 를 생성한다. 최종 결과는 순방향 기구학(Forward Kinematics)을 거쳐 2D 스켈레톤 포즈로 복원된다. 포즈는 11개 주요 뼈대의 방위각과 고도각을 결합한 22차원 벡터로 구성되며, 편집 과정에서 비현실적 골격 변형이 완화된도록 하였다.

3.2 편집 지시어와 학습 데이터 구성

편집 명령은 5개 신체 부위(척추, 좌/우 팔, 좌/우 다리)와 2개 방향을 조합한 10개 카테고리로 정의한다. 각 카테고리는 편집 대상 부위의 마스크와 핵심 각도에 대한 임계값 기반 목표 방향을 가진

* 이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원-학·석사연계ICT핵심인재양성사업의 지원을 받아 수행된 연구임(IITP-2026-RS-2022-00156299)



(그림 1) 제안하는 스켈레톤 포즈 편집 파이프라인

다. 예를 들어, “왼팔 올리기”는 왼팔 부위 마스크와 왼팔 상단 뼈대가 위쪽 방향을 갖도록 하는 조건에 대응된다. 학습 시에는 HumanML3D[4]의 각 포즈를 타겟(target)으로 사용하고, 핵심 각도 값을 기준으로 편집 명령 라벨을 자동 부여한다. 편집 부위를 마스크한 포즈를 소스(source)로 구성하여, 별도의 편집 쌍(annotation) 없이 자기 지도 방식의 학습 데이터 96,048개를 생성하였다.

3.3 확산 모델 학습 및 추론

제안 모델은 4-layer MLP 기반 노이즈 예측 네트워크로 구성된다. 입력은 노이즈가 추가된 포즈 $x_t(22D)$, 타임스텝 임베딩(128D), 편집 지시어 임베딩(16D), 마스크된 원본 포즈 $x_{src} \odot (1 - m)(22D)$, 편집 부위 마스크 $m(22D)$ 를 결합한 210차원 벡터이며, 출력은 예측 노이즈 $\hat{\epsilon}(22D)$ 이다. 학습은 편집 영역에 더 큰 가중치를 부여한 평균 제곱 오차로 수행하며, 명령 카테고리 불균형 완화를 위해 WeightedRandomSampler를 적용하였다. 추론 시에는 가우시안 노이즈 $x_T \sim N(0, I)$ 에서 시작하여 DDPM(Denoising Diffusion Probabilistic Models) [5]의 역방향 과정을 $T=100$ 스텝 동안 수행한다. 각 스텝에서 모델 예측으로 x_t 를 갱신하는 동시에, 비편집 영역 ($m = 0$)에는 원본 포즈로부터 유도된 값을 덮어쓰는 인페인팅 트릭을 적용한다. 이를 통해 편집 부위만 자유롭게 생성하고, 나머지 영역은 원본 자세를 유지하도록 한다. 최종 결과는 역정규화와 각도 범위 클리핑 후 스켈레톤 포즈로 복원된다.

4. 실험


학습에는 HumanML3D로부터 구축한 96,048개의 샘플을 사용하였다. 평가는 세 지표로 수행하였다. ISR(Instruction Success Rate, $\uparrow$)은 편집 결과가 지시 방향과 일치하는 비율로, 편집 명령 일치성을 측정한다. SP(Source Preservation, $\downarrow$)는 비편집 영역의 생성 결과와 원본 간 L2 거리로, 원본 보존 품질을 평가한다. ED(Edit Diversity, $\uparrow$)는 동일 조건의 생성 샘플 간 편집 영역 pairwise L2 거리 평균으로, 편집 다양성을 나타낸다. 표 1과 같이 제안 방법은 평균 ISR 96.7%, SP 0.38, ED 2.30을 기록하였다. 이는 원본 데이터셋 다양성($ED_{real} = 3.47$)의 약 66% 수준으로, 명령 제약하에서도 자연스러운 다양성을 유지함을 보여준다. 그림 2의 정성 결과에서도 비편집 영역은 원본과 동일하게 유지되고, 편집 부위는 지시어 방향에 맞게 자연스럽게 수정됨을 확인할 수 있다.

(표 1) 실험 결과

Part	ISR($\uparrow$)	SP($\downarrow$)	ED($\uparrow$)
Spine	94.3%	0.16	2.72
Arms(avg)	96.8%	0.37	2.19
Legs(avg)	97.8%	0.52	2.20
Overall	96.7%	0.38	2.30

5. 결론

본 논문에서는 정적 2D 스켈레톤 포즈의 부위별 편집을 위한 텍스트 지시어 기반 마스크 조건부 확산 모델을 제안하였다. 자연어 지시어를 10개 편집 명령 카테고리로 매핑하고, 해당 부위 마스크와 함께 조건으로 사용하여 편집 부위만 선택적으로 수정하는 구조를 설계하였다. 또한 각 뼈대의 방향을 방위각과 고도각으로 나타낸 22차원 벡터를 사용하고 인페인팅 기법을 결합함으로써, 비편집 영역은 유지하면서 편집 과정에서 비현실적인 골격 변형이 완화된도록 하였다. 실험 결과, 제안 방법은 평균 96.7%의 명령 일치율과 실제 데이터 대비 약 66% 수준의 편집 다양성을 보여, 정적 2D 포즈 편집에서 지시어 반영과 구조 보존이 가능함을 확인하였다.



(그림 2) 지시어에 따른 포즈 편집 예시

참고 문헌

- [1] G. Tevet et al., "Human Motion Diffusion Model", In Proceedings of the International Conference on Learning Representations, 2023.
- [2] M. Zhang et al., "MotionDiffuse: Text-Driven Human Motion Generation with Diffusion Model", IEEE Transactions on Pattern Analysis and Machine Intelligence, Vol.46, No.6, 2024. pp.4115–4128.
- [3] N. Athanasiou et al., "MotionFix: Text-Driven 3D Human Motion Editing", In SIGGRAPH Asia 2024 Conference Papers, 2024. pp.1–11.
- [4] C. Guo et al., "Generating Diverse and Natural 3D Human Motions From Text", In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022. pp.5152–5161.
- [5] J. Ho et al., "Denoising Diffusion Probabilistic Models", In Advances in Neural Information Processing Systems, Vol.33, 2020. pp.6840–6851.